

第一阶段（QLoRA微调） 评估结果及评估方法

Part 1 评估结果一览

QLoRA微调训练过程评估（saves/qwen3-30b-alert-analysis）

复制代码

```
{
  "epoch": 3.0,
  "eval_loss": 0.028932970017194748,
  "eval_runtime": 380.1038,
  "eval_samples_per_second": 0.263,
  "eval_steps_per_second": 0.034,
  "total_flos": 2.7074321172135936e+16,
  "train_loss": 0.2991791720191638,
  "train_runtime": 37084.4302,
  "train_samples_per_second": 0.073,
  "train_steps_per_second": 0.001
}
```

基础模型NLG评估结果（saves/qwen3-30b-alert-analysis/base_eval_results）

复制代码

```
{
  "predict_bleu-4": 7.281834615384615,
  "predict_model_preparation_time": 0.0414,
  "predict_rouge-1": 20.229741346153848,
  "predict_rouge-2": 10.560779807692306,
  "predict_rouge-l": 9.856879807692307,
  "predict_runtime": 11652.5981,
  "predict_samples_per_second": 0.009,
  "predict_steps_per_second": 0.001
}
```

合并后模型的NLG评估结果 (saves/qwen3-30b-alert-analysis/merged_eval_results)

[复制代码](#)

```
{
  "predict_bleu-4": 95.97160384615384,
  "predict_model_preparation_time": 0.0407,
  "predict_rouge-1": 96.70943173076923,
  "predict_rouge-2": 95.79738942307692,
  "predict_rouge-l": 97.0707480769231,
  "predict_runtime": 1780.1313,
  "predict_samples_per_second": 0.056,
  "predict_steps_per_second": 0.007
}
```

Part 2: 详细的评估流程

Step 0: 训练过程评估 (对训练过程的状态进行评估, 如损失曲线等)

评估相关配置:

[复制代码](#)

```
### eval
val_size: 0.1
per_device_eval_batch_size: 1
eval_strategy: steps
eval_steps: 500
```

评估输出目录:

[复制代码](#)

```
output_dir: saves/qwen3-30b-alert-analysis
```

具体评估结果:

[复制代码](#)

```
"epoch": 3.0,
  "eval_loss": 0.028932970017194748,
  "eval_runtime": 380.1038,
  "eval_samples_per_second": 0.263,
  "eval_steps_per_second": 0.034
"epoch": 3.0,
```

```
"eval_loss": 0.028932970017194748,  
"eval_runtime": 380.1038,  
"eval_samples_per_second": 0.263,  
"eval_steps_per_second": 0.034,  
"total_flos": 2.7074321172135936e+16,  
"train_loss": 0.2991791720191638,  
"train_runtime": 37084.4302,  
"train_samples_per_second": 0.073,  
"train_steps_per_second": 0.001
```

Step 1: 基础模型NLG评估

评估配置文件:



复制代码

configs/qwen3-eval.yaml

配置内容:



复制代码

```
### model  
model_name_or_path: /mnt/ai_projects/ai_soc_project/LLaMA-  
Factory/models/qwen/Qwen3-30B-A3B  
quantization_bit: 4  
trust_remote_code: true  
  
### method  
stage: sft  
do_predict: true  
  
### dataset  
  
eval_dataset: alert_analysis_dataset  
template: qwen3  
cutoff_len: 2048  
max_samples: 100  
overwrite_cache: true  
preprocessing_num_workers: 8  
  
### output  
output_dir: saves/qwen3-30b-alert-analysis/base_eval_results  
overwrite_output_dir: true  
  
### eval  
per_device_eval_batch_size: 1
```

```
predict_with_generate: true
ddp_timeout: 180000000
```

评估输出目录：



复制代码

```
saves/qwen3-30b-alert-analysis/base_eval_results
```

具体评估结果：



复制代码

```
"predict_bleu-4": 7.281834615384615,
"predict_model_preparation_time": 0.0414,
"predict_rouge-1": 20.229741346153848,
"predict_rouge-2": 10.560779807692306,
"predict_rouge-l": 9.856879807692307,
"predict_runtime": 11652.5981,
"predict_samples_per_second": 0.009,
"predict_steps_per_second": 0.001
```

评估指令：



复制代码

```
llamafactory-cli train configs/qwen3-eval.yaml
```

Step 2: 合并基础模型与LoRA适配器

合并配置文件：（configs/merge_qwen3_30b_lora.yaml）



复制代码

```
### model
model_name_or_path: /mnt/ai_projects/ai_soc_project/LLaMA-Factory/models/qwen/Qwen3-30B-A3B
adapter_name_or_path: /mnt/ai_projects/ai_soc_project/LLaMA-Factory/saves/qwen3-30b-alert-analysis
template: qwen3
finetuning_type: lora

### export
export_dir: /mnt/ai_projects/ai_soc_project/LLaMA-Factory/models/qwen3-30b-alert-analysis-merged
export_size: 2
export_device: cpu
export_legacy_format: false
```

合并指令：



复制代码

```
llamafactory-cli export configs/merge_qwen3_30b_lora.yaml
```

Step 3: 合并后模型NLG评估

评估配置文件 (configs/qwen3-merged-eval.yaml)



复制代码

```
### model
model_name_or_path: /mnt/ai_projects/ai_soc_project/LLaMA-Factory/models/qwen3-30b-alert-analysis-merged
trust_remote_code: true
quantization_bit: 4

### method
stage: sft
do_predict: true

### dataset
eval_dataset: alert_analysis_dataset
template: qwen3
cutoff_len: 2048
max_samples: 100
overwrite_cache: true
preprocessing_num_workers: 4

### output
output_dir: saves/qwen3-30b-alert-analysis/merged_eval_results
overwrite_output_dir: true

### eval
per_device_eval_batch_size: 1
predict_with_generate: true
ddp_timeout: 180000000
```

评估输出目录：



复制代码

```
saves/qwen3-30b-alert-analysis/merged_eval_results
```

具体评估结果：

```
"predict_bleu-4": 95.97160384615384,  
"predict_model_preparation_time": 0.0407,  
"predict_rouge-1": 96.70943173076923,  
"predict_rouge-2": 95.79738942307692,  
"predict_rouge-l": 97.0707480769231,  
"predict_runtime": 1780.1313,  
"predict_samples_per_second": 0.056,  
"predict_steps_per_second": 0.007
```

评估指令：

```
llamafactory-cli train configs/qwen3-merged-eval.yaml
```

注1：从微调训练的数据集中预留了十分之一用于评估（合计1500条），该评估数据未参与微调训练。虽然训练数据和评估数据有很大的相似度，属于同类数据，但是由于评估数据集未参与实际训练，故在该数据集上进行评估能较好地反映大模型针对安全告警分析特定场景的泛化能力。

注2：为控制评估时间，对基础模型和合并后模型的评估数据是从上述1500条数据样本中随机抽样的100条数据样本。

附录1：评估结果重要字段的具体含义

文本生成质量指标：

- predict_bleu-4：机器翻译质量评估指标，使用4-gram匹配，范围0-100，越高越好
- predict_rouge-1：基于unigram的召回率，衡量词汇覆盖度
- predict_rouge-2：基于bigram的召回率，衡量短语级别匹配
- predict_rouge-l：基于最长公共子序列，衡量句子结构相似性

性能指标：

- predict_runtime：模型完成预测任务的总耗时（秒）
- predict_samples_per_second：每秒处理的样本数量
- predict_steps_per_second：每秒完成的处理步骤数
- predict_model_preparation_time：模型加载和初始化时间（秒）

附录2：综合分析

评估数据说明：

- 从微调训练数据集中预留10%（1500条）用于评估，未参与训练

- 基础模型和合并后模型评估使用随机抽样的100条数据样本

性能对比分析：

文本生成质量显著提升：

- BLEU-4：从7.28提升至95.97（提升13.2倍）
- ROUGE-1：从20.23提升至96.71（提升4.8倍）
- ROUGE-2：从10.56提升至95.80（提升9.1倍）
- ROUGE-L：从9.86提升至97.07（提升9.8倍）

训练过程表现：

- 最终评估损失：0.0289，表明模型拟合良好
- 训练总耗时：37084.4秒（约10.3小时）
- 浮点运算总量： 2.71×10^{16} FLOPs

结论：

QLoRA微调在安全告警分析任务上取得了显著效果，文本生成质量指标接近完美，同时推理效率得到明显改善，证明了微调策略的有效性和实用性。